Polycopié 5 - v.1 20110318

## Intervalles de confiance

**Définition 1.** Soient Y une v.a. réelle et  $\alpha \in ]0, 1[$ . On appelle quantile d'ordre  $\alpha$  de Y le nombre  $q_{\alpha}$  tel que

$$q_{\alpha} = \inf \{ y \in \mathbb{R} : F_Y(y) \ge \alpha \}.$$

## Propriétés:

- 1. On a  $\mathbb{P}(Y \leq q_{\alpha}) = F_Y(q_{\alpha}) \geqslant \alpha$ . Si Y est une v.a. continue  $F_Y(q_{\alpha}) = \alpha$ .
- 2. Si Y est une v.a. continue la fonction  $q_{\alpha}: ]0,1[ \to \{x: f_Y(x) > 0\}]$  est bijective et continue.
- 3. Si Y est une v.a. continue alors pour tout  $0 \le \beta \le \gamma \le 1$  :

$$\mathbb{P}(q_{\beta} < Y \le q_{\gamma}) = \mathbb{P}(Y \le q_{\gamma}) - \mathbb{P}(Y \le q_{\beta}) = \gamma - \beta.$$

- 4. Si  $f_Y$  est une fonction paire (= la loi de Y est symétrique autour de zéro, -Y a la même loi de Y) alors  $q_{1-\alpha} = -q_{\alpha}$ .
- 5.  $q_{1/2}$  est la médiane.  $q_{1/4}$  le premier quartile.

## Problème

Une entreprise reçoit d'un de ses fournisseurs un lot de pièces qui doit "normalement" contenir une proportion  $\theta \leq 10\%$  de pièces défectueuses. L'entreprise voudrait, par examen d'un échantillon de taille n, décider entre  $\theta \leq 10\%$  et  $\theta > 10\%$ , sachant qu'elle acceptera le lot dans le premier cas et le rejettera dans le deuxième cas.

On définit

$$X_i \! = \! \left\{ \begin{array}{l} 1 \ \ \text{si la pièce prélevée est défectueuse} \ ; \\ 0 \ \ \text{sinon}. \end{array} \right.$$

 $X_1, ..., X_n$  sont n variables iid de loi de Bernoulli de paramètre  $\theta$  qui composent l'échantillon  $\mathbf{X}$ . L'EMV est  $\hat{\theta}_n = \overline{X}_n$  (égale à l'estimateur par méthode des moments).

Supposons n = 100 et que on observe  $\overline{X}_n = 0.195$ .

Question: Quelle décision l'entreprise doit prendre? Accepter ou rejeter le lot? Et, sur quel critère l'entreprise doit se baser pour prendre sa décision?

**Définition 2.** Soit  $\mathcal{P} = \{\mathbb{P}_{\theta} : \theta \in \Theta\}$  un modèle paramétrique. On dispose d'un échantillon  $\mathbb{X} = (X_1, ..., X_n)$  de n v.a.  $iid \sim \mathbb{P}_{\theta}$ . Soient  $A_n$  et  $B_n$  deux statistiques. On dira que  $[A_n, B_n]$  est un intervalle de confiance de niveau  $1 - \alpha$  pour  $\theta$  si

$$\mathbb{P}_{\theta}(A_n \le \theta \le B_n) = 1 - \alpha$$

pour tout  $\theta \in \Theta$ .

On dira que  $[A_n, B_n]$  est un intervalle de confiance de niveau asymptotiquement égal à  $1 - \alpha$  pour  $\theta$  si

$$\lim_{n \to \infty} \mathbb{P}_{\theta}(A_n \le \theta \le B_n) = 1 - \alpha$$

pour tout  $\theta \in \Theta$ .

**Remarque:** Dans les applications on utilise souvent les valeurs  $\alpha = 0.05, 0.01$ .

**Exemple 3.** Soit  $X \sim \mathcal{N}(\mu, 1)$ ,  $\mu \in \mathbb{R}$  notre modèle paramétrique. Soient  $\zeta_{\alpha}$  les quantiles de la v.a. Gaussienne standard (centrée et réduite). On pose  $A_n = \overline{X}_n - \zeta_{\gamma}/\sqrt{n}$  et  $B_n = \overline{X}_n - \zeta_{\beta}/\sqrt{n}$ .

On veut déterminer  $\beta$  et  $\gamma$  dans [0, 1] tels que  $[A_n, B_n]$  soit un intervalle de confiance de niveau  $1 - \alpha$  pour  $\mu$ .

La v.a.  $\bar{X}_n$  est une Gaussienne de moyenne  $\mu$  et variance 1/n donc

$$\mathbb{P}(A_n \leqslant \mu \leqslant B_n) = \mathbb{P}(A_n \leqslant \mu, \mu \leqslant B_n) = \mathbb{P}(\overline{X}_n - \zeta_\gamma / \sqrt{n} \leqslant \mu, \mu \leqslant \overline{X}_n - \zeta_\beta / \sqrt{n})$$

$$= \mathbb{P}(\sqrt{n}(\overline{X}_n - \mu) \leqslant \zeta_\gamma, \zeta_\beta \leqslant \sqrt{n}(\overline{X}_n - \mu)) = \mathbb{P}(\zeta_\beta \leqslant \sqrt{n}(\overline{X}_n - \mu) \leqslant \zeta_\gamma)$$

$$= \mathbb{P}(\zeta_\beta \leqslant Z \leqslant \zeta_\gamma) = \mathbb{P}(Z \leqslant \zeta_\gamma) - \mathbb{P}(Z \leqslant \zeta_\beta)$$

où  $Z \sim \mathcal{N}(0, 1)$ . Par la définition des quantiles Gaussiens on a que  $\mathbb{P}(\mathbb{Z} \leqslant \zeta_r) = r$  pour tout  $r \in ]0, 1[$  et donc

$$1 - \alpha = \mathbb{P}(A_n \leqslant \mu \leqslant B_n) = \gamma - \beta$$

est la condition à imposer sur  $\gamma, \beta$  pour avoir un intervalle de confiance à niveau  $1-\alpha$ .

## Remarque 4.

- Il existe un nombre infini des intervalles de confiance de niveau  $1-\alpha$ .
- Si  $\beta \neq 0$  et  $\gamma \neq 1$  on parlera d'un intervalle de confiance bilatérale.
- Si  $\beta = 0$  ( $\gamma = 1 \alpha$ ) ou si  $\gamma = 1$  ( $\beta = \alpha$ ) on parlera d'un intervalle de confiance unilatéral.
- Si  $\beta = \alpha/2$  et  $\gamma = 1 \alpha/2$  on parlera d'un intervalle de confiance bilatéral symétrique.
- Valeurs utiles de  $\zeta_{\alpha}$ :  $\zeta_{1/2} = 0$ ,  $\zeta_{0.9} = 1.28$ ,  $\zeta_{0.9} = 1.645$ ,  $\zeta_{0.975} = 1.96$ ,  $\zeta_{0.995} = 2.58$ .

Remarque 5. Dans le cas Gaussien où l'échantillon est tiré de la loi  $\mathcal{N}(\mu, \sigma_0^2)$  avec variance  $\sigma_0^2$  connue, les intervalles plus utilisé sont

• Les intervalles unilatéraux

$$\mathbb{P}(\mu \geqslant \bar{X}_n - \frac{\sigma_0}{\sqrt{n}}\zeta_{1-\alpha}) = \mathbb{P}(\mu \leqslant \bar{X}_n + \frac{\sigma_0}{\sqrt{n}}\zeta_{1-\alpha}) = 1 - \alpha;$$

• L'intervalle bilatérale symétrique:

$$\mathbb{P}(\bar{X}_n - \frac{\sigma_0}{\sqrt{n}}\zeta_{1-\alpha/2} \leqslant \mu \leqslant \bar{X}_n + \frac{\sigma_0}{\sqrt{n}}\zeta_{1-\alpha/2}) = 1 - \alpha.$$

**Exemple 6.** Reprenons le problème introductif.  $X \sim \text{Ber}(\theta)$ . L'EMV pour  $\theta$  est  $\overline{X}_n$ . Par le TCL:

$$\frac{\sqrt{n}(X_n - \theta)}{\sqrt{\theta(1 - \theta)}} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1)$$

Par la loi des grandes nombres  $\overline{X}_n \xrightarrow{p.s.} \theta$  et donc par le lemme de continuité appliqué à la fonction  $g(x) = \sqrt{x(1-x)}$  on a aussi

$$g(\overline{X}_n) = \sqrt{X_n(1-X_n)} \xrightarrow{p.s.} \sqrt{\theta(1-\theta)}.$$

On peut conclure par le lemme de Slutsky que

$$\frac{\sqrt{n}(X_n-\theta)}{\sqrt{X_n(1-X_n)}} = \frac{\sqrt{n}(X_n-\theta)}{\sqrt{\theta(1-\theta)}} \frac{\sqrt{\theta(1-\theta)}.}{X_n(1-X_n)} \xrightarrow{\mathcal{L}} \mathcal{N}(0,1).$$

Donc asymptotiquement l'intervalle de confiance symétrique bilatérale pour  $\theta$  est donné par

$$\bar{X}_n - n^{-1/2} (\bar{X}_n (1 - \bar{X}_n))^{1/2} \zeta_{1-\alpha/2} \leq \theta \leq \bar{X}_n + n^{-1/2} (\bar{X}_n (1 - \bar{X}_n))^{1/2} \zeta_{1-\alpha/2}$$
.

**Application:** Si on fixe  $\alpha = 0.05$ . Pour la valeur observé de  $\overline{X}_n = 0.195$  (n = 100) on a que l'intervalle de confiance trouvé dans l'exemple précèdent est

$$\theta \in [0.117, 0.273]$$

(vérifier). Ce qui permet de rejeter le lot avec niveau de confiance 95%.